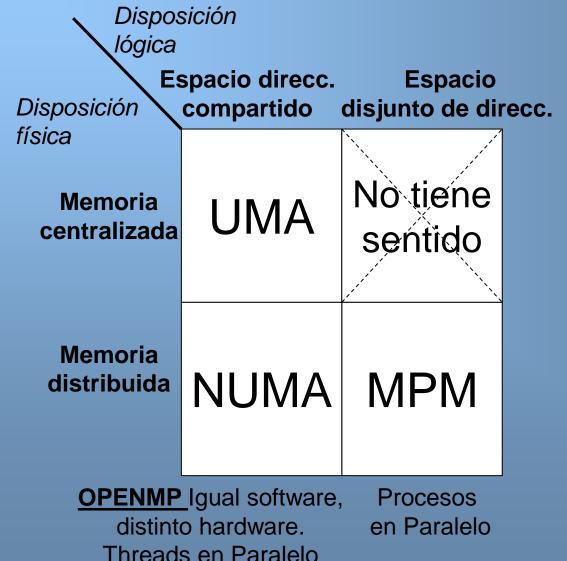
TUTORIAL OPENMP

ARQUITECTURA DE SISTEMAS DISTRIBUIDOS

www.atc.us.es

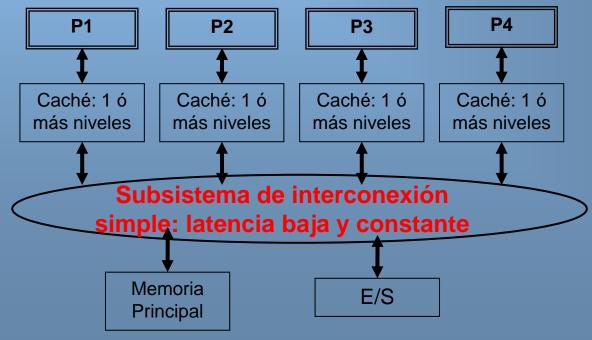
Dpto. de Arquitectura y Tecnología de Computadores. Universidad de Sevilla

- . Taxonomía y modelos de procesamiento paralelo
- Según Organización de la memoria principal



UMA (Uniform Memory Access)

- -Tiempo de acceso uniforme para toda dirección
- -Tb .llamados SMP's (Multiprocesadores simétricos)
- -Ej: casi todos los multicore actuales
- -Cuello de botella: acceso a memoria principal:
 - Grandes cachés en cada procesador
 - •AB solicitado por cada procesador crece cada vez más
 - •Número de procesadores no puede ser alto. Hoy N≤32.



Coherencia entre cachés

- Comunicación implícita (variables compartidas)
- Una misma línea replicada en varios procesadores
 - ⇒ Hard adicional para solucionarlo.
- En UMA: Protocolos de husmeo (snooping):
 - Protocolo ISX (y otros): similar al de Copy Back
 - Línea Inválida (Invalid)
 - Línea Compartida (Shared)
 - Línea eXclusiva (eXclusive)

P1 P2
int a[4];
a[0]++; a[0]++;
a[1]++; a[2]++;

CUIDADO: falsas comparticiones (false sharing).

Herramientas de programación

- Muchos intentos (y siguen...)
- Lenguaje de programación paralelo:
 - No es factible: Difícil de imponer
- Espacio de direcciones compartido
 - OpenMP: estándar (varios fabricantes) de directivas del precompilador.
- Espacio de direcciones disjuntos: clusters de computación.
 - Librería Message Passing Interface (MPI):
 especificación para librerías de paso de mensajes

OpenMP

- Modelo de programación paralela
 - Directivas del precompilador
 - Tb. Pequeña API
- Paralelismo de memoria compartida
- Fácil para bucles (paralelizables directa o indirectamente)
- Extensiones a lenguajes de programación existentes (Fortran, C, C++)

Sintaxis de OpenMP

Pragma en C y C++:

```
#pragma omp construct [clause [clause]...]
```

En Fortran, directivas :

```
C$OMP construct [clause [clause]...]
!$OMP construct [clause [clause]...]
*$OMP construct [clause [clause]...]
```

- Un programa puede ser compilado por compiladores que no soportan OpenMP.
 - ATENCIÓN: NO olvidar "Compatiblidad
 OpenMP" en el compilador

Programa sencillo

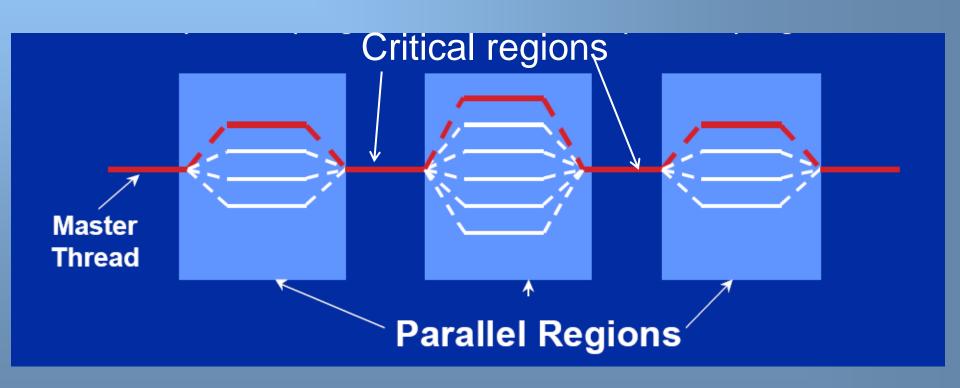
Programa Secuencial

```
void main() {
  double a[1000],b[1000],c[1000];
  for (int i = 0; i < 1000; i++) {
     a[i] = b[i] + c[i];
  }
}</pre>
```

Programa Paralelo

```
void main() {
  double a[1000],b[1000],c[1000];
#pragma omp parallel for
  for (int i = 0; i < 1000; i++) {
    a[i] = b[i] + c[i];
  }
}</pre>
```

Regiones paralelas y críticas (I)



OpenMP runtime library

```
omp_get_num_threads()
```

- devuelve el número actual de threads omp_get_thread_num()
- devuelve el identificador de ese thread omp_set_num_threads(n)
- activa el número de threads

```
¿Qué parte le corresponde al hilo 0 de este bucle (usar estas func.)? ¿Y al hilo k ? for (int i = 0; i < n; i++) {...}
```

Declarando Ámbito de datos (I)

- shared: variable es compartida por todos los procesos. Ej: vectores del proceso.
- private: Cada proceso tiene una copia

```
#pragma omp parallel for
    shared(a,b,c,n) private(i, temp)
for (i = 0; i < n; i++) {
    temp = a[i]/b[i];
    a[i] = b[i] + temp * c[i];
}</pre>
```

- Hay reglas para decidir por defecto el ámbito, pero mejor no arriesgarse
- CUIDADO: false sharing CUIDADO: false sharing CUIDADO: false sharing CUIDADO: float a[2], b[2], c[2];?

Declarando Ámbito de datos (II)

 Variables REDUCTION: operaciones colectivas sobre elementos de un array

```
asum = 0.0;
aprod = 1.0;
#pragma omp parallel for reduction(+:asum)
reduction(*:aprod)
for (i = 0; i < n; i++) {
  asum = asum + a[i];
  aprod = aprod * a[i];
}
```

EJEMPLO: Cálculo de PI (Secuencial)

```
static long num steps = 100000;
double step;
void main () {
int i; double x, pi, sum = 0.0;
step = 1.0/(double) num steps;
for (i=1;i<= num steps; i++) {
   x = (i-0.5) * step;
    sum = sum + 4.0/(1.0+x*x);
                                  \left| arctg'(x) = \frac{1}{1+x^2} \right|
pi = step * sum;
                                      \left. \begin{array}{l} \operatorname{arct}g(1) = \frac{\pi}{4} \\ \operatorname{arct}g(0) = 0 \end{array} \right\} \Rightarrow \int_{0}^{1} \frac{1}{1+x^{2}} = \operatorname{arct}g(x) \Big|_{0}^{1} = \frac{\pi}{4} - 0 \Big|_{0}^{1}
                                                                               ASD. . 13
```

EJEMPLO: Cálculo de PI (Omp Reduction)

```
#include <omp.h>
static long num steps = 100000; double step;
void main () {
int i; double x, pi, sum = 0.0;
step = 1.0/(double) num steps;
omp set num threads(2);
#pragma omp parallel for reduction(+:sum)
 private(x)
for (i=1;i<= num steps; i++) {
  x = (i-0.5) * step;
  sum = sum + 4.0/(1.0+x*x);
pi = step * sum;
                                          ASD. . 14
```

Cálculo de PI: omp "reducción artesana"

```
#include <omp.h>
static long num steps = 100000; double step;
void main () {
int i; double x, pi, sum[2];
step = 1.0/(double) num steps;
                                      ¿Qué le pasa al 'for'
omp set num threads (2);
                                       comentado?
#pragma omp parallel
{ double x; int id;
  id = omp get thread num();
  //for (i=id, sum[id]=0.0;i \le num steps; i=i+2){}
  for (i=id* num steps/2, sum[id]=0.0;
      i<= (id+1) * num steps/2; i++ )
          x = (i+0.5) * step;
          sum[id] += 4.0/(1.0+x*x);
for(i=0, pi=0.0;i<2;i++) pi+=sum[i]*step;
```

Planificación de Tareas: SCHEDULE (I)

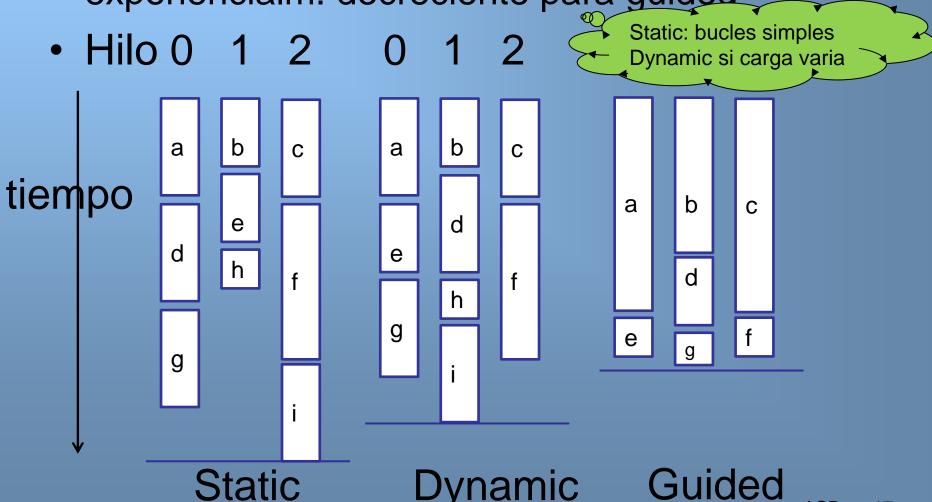
Diferentes formas de asignar iteraciones a threads

- schedule(static [,chunk])
 - "chunk" iteraciones se asignan de manera estática a los threads en round-robin
- schedule (dynamic [,chunk])
 - Cada thread toma "chunk" iteraciones cada vez que está sin trabajo
- schedule (guided [,chunk])
 - Cada thread toma progresivamente menos iteraciones (dinámicamente)

Planificación de Tareas: SCHEDULE (II)

igual num iteraciones para static, dynamic.

· exponencialm. decreciente para guided



ASD. . 17

Regiones Paralelas

```
#pragma omp parallel
/* Bloque básico replicado (ejecutado) por
  cada thread */
                  foo(1,...)
                                          foo(3,...)
      foo(0,...)
                              foo(2,...)
                                          omp_set_num_threads(4);
      printf("%d\n", i)
                                          #pragma omp parallel
                                           o i = omp_thread_num();
                                            foo(i,a,b,c);
                Control de tareas en
                f(thread_id). Pag 19
                                          #pragma omp end parallel
                🚜 Qué imprime? 🏃
                                          printf("%d\n", i);
```

Secciones (una por hilo)

```
#pragma omp parallel sections
  #pragma omp section
 printf ("id s1=%d,\n",omp get thread num());
  for (i=0; i<tam/2; i++)
     y[i] = a*x[i] + y[i];
  #pragma omp section
 printf ("id s2=%d,\n",omp get thread num());
 for (i=tam/2; i<tam; i++)
    y[i] = a*x[i] + y[i];
                             Escribir esto con
                              #pragma omp parallel
                              (pag anterior)
```

Regiones paralelas y críticas

- Los threads se comunican utilizando variables compartidas.
- El uso inadecuado de variables compartidas origina carreras
- Uso de sincronización o exclusión para evitarlas

 NOTA: sincronización es muy costosa en tiempo: usar lo menos posible

Exclusión Mutua: Sección Crítica

```
#pragma omp parallel shared(x,y)
#pragma omp critical (section1)
 actualiza(x); //only one thread
 usa(x);
#pragma omp critical(section2)
 actualiza(y); //only one thread
 usa (y) ; Qué ocurre si no se
               declara la sección crítica?
```

Exclusión Mutua: Sección Crítica EJ.

no se declara como crítico? cnt=0 C++: cnt = 0;f=7 f=7; i= 5,9 #pragma omp parallel 10,14 15,19 #pragma omp for if... if... if... for (i=0; i<20; i++) { cnt++ if (b[i] == 0) { cnt++ a[i]= #pragma omp critical b[i]+.. cnt++ a[i]= cnt ++; b[i]+... cnt++ a[i]= b[i]+... a[i]= a[i] = b[i] + f * (i+1);} /* end for */ } /*omp end parallel */

¿Qué pasa si cnt++

Sincronización: Barreras

Los threads se detienen hasta que alcancen la barrera nt=omp get num threads(); #pragma omp parallel private (i, id) id=omp get thread num(); for (i=id*tam/nt; i<(id+1)*tam/nt; i++) { y[i] = a*x[i] + y[i];#pragma omp barrier // aquí seguro que todo y[] está actualizado for (i=id*tam/nt; i<(id+1)*tam/nt; i++) { z[i] = b + y[tam-i-1];¿Qué pasa si se fusionan los bucles? ASD. . 23